

ESCUELA INTERNACIONAL DE DOCTORADO

Programa de Doctorado Tecnologías de la Computación e Ingeniería Ambiental

**Caracterizar y reducir la brecha entre el
rendimiento en banco de pruebas y el despliegue
operativo de la detección de anomalías en
sistemas de control industrial de agua: un estudio
sobre series temporales de la capa OT**

Autor:

David Palazón Palau

Directores:

Dr. D. Juan Miguel Navarro Ruiz

Dr. D. Antonio Pita Lozano

Murcia, Junio de 2026

1. Resumen del proyecto de tesis

Esta propuesta estudia por qué la detección de anomalías que alcanza un rendimiento alto en banco de pruebas pierde eficacia al trasladarse a la operación de los sistemas de control industrial (ICS, del inglés *Industrial Control Systems*) de agua, y qué reduce esa brecha. El objeto de la investigación no es un detector concreto ni un catálogo de obstáculos, sino la brecha misma entre el rendimiento publicado y la utilidad operativa, y la pregunta que la organiza: por qué los modelos fracasan al desplegarse y cómo puede acortarse esa distancia. El dominio se acota a las series temporales multivariantes de la capa de tecnología de operación (OT, del inglés *Operational Technology*) (la telemetría del proceso físico, en los niveles 0 a 2 de la pila de Purdue), no a la capa de tecnología de la información ni al tráfico de red. Los bancos de pruebas públicos y etiquetados del dominio (SWaT, WADI, HAI y BATADAL) se tratan, en consecuencia, como objeto de estudio crítico y no como campo de aplicación.

La hipótesis central, de carácter explicativo, sostiene que esa brecha no es un artefacto aleatorio, sino el efecto de un conjunto identificable de factores: unos metodológicos, propios de cómo se evalúa, la selección de umbral con oráculo sobre el conjunto de prueba (*best-F1 / oracle thresholding*) y el ajuste por puntos (*point adjustment*), y otros propios de la naturaleza del sistema (la no estacionariedad y la dependencia del régimen operativo). El efecto observado de cada factor sobre el rendimiento puede aislarse y estimarse dentro de un diseño experimental controlado; el trabajo no promete resolver la brecha, sino demostrarla y medir su composición.

Sobre ese diagnóstico, una hipótesis de trabajo propone un mecanismo de detección. El estado operativo de la planta es latente y se manifiesta en asociaciones estables entre las variables medidas; bajo las mismas condiciones exógenas y el mismo régimen, esas asociaciones se mantienen, y su ruptura es un indicador de anomalía más robusto frente a la deriva que el valor individual de cada variable o que una puntuación agregada umbralizada de forma global. Como el criterio de normalidad se condiciona al régimen, la alarma identifica de forma nativa qué asociación y en qué régimen se ha roto: una explicación que describe el evento detectado, sin afirmación causal sobre su origen físico.

La validación se realiza sobre los bancos públicos etiquetados, con un panel de métricas sensibles al despliegue (volumen bajo la superficie, métricas de afiliación, F-compuesta por eventos y evaluación bajo presupuesto de alarmas) y con baselines triviales como prueba de cordura. No se afirma reducir la brecha en una planta real concreta: los datos de planta sin etiquetar, procedentes del contexto aplicado del proyecto TrueData en el que ha participado el grupo de investigación GRITA de la Universidad Católica de Murcia (UCAM), carecen de verdad de referencia de ataques y se emplean como evidencia descriptiva del problema (prueba de concepto y trabajo futuro), no como fuente de métricas de detección. La contribución se sitúa en la integración (detección por ruptura de

asociaciones condicionada al régimen, protocolo de transferencia entre plantas y evaluación realista de despliegue) aplicada específicamente a las series OT del proceso de agua, más que en cada una de esas piezas por separado.

Palabras clave: detección de anomalías; series temporales multivariantes de la capa OT; sistemas de control industrial de agua; ciberseguridad de infraestructuras críticas; niveles 0-2 de la pila de Purdue; evaluación realista de despliegue; deriva de concepto y *normality shift*; régimen operativo; transferibilidad banco de pruebas–planta; interpretabilidad de alarmas.

2. Objetivos científicos e hipótesis

2.1. Objetivos

La investigación se encuadra en la línea de Tecnologías Multimedia del programa de Doctorado en Tecnologías de la Computación e Ingeniería Ambiental, dentro de la detección sobre series temporales de la capa OT del proceso físico de agua (niveles 0-2 de Purdue), la inteligencia artificial aplicada y la protección de infraestructuras críticas.

El objetivo general es caracterizar y reducir la brecha entre el rendimiento en banco de pruebas y la utilidad operativa de la detección de anomalías en sistemas de control industrial de agua: estimar el efecto observado de los factores que la producen y proponer un mecanismo de detección más robusto frente a las condiciones de despliegue, sobre series temporales de la capa OT. Los objetivos específicos operacionalizan ese fin en cuatro paquetes de trabajo y un hilo teórico transversal:

1. **Fijar el marco conceptual** del trabajo (estado operativo latente, asociaciones estables entre variables, distinción endógeno/exógeno, papeles diferenciados del modelo de información y de la ontología, y delimitación del alcance a las series OT en los niveles 0-2 de Purdue), que da sustrato a las demás líneas (WP0).

2. **Tipificar los factores de la brecha** mediante una revisión propia acotada a la brecha (no una revisión sistemática exhaustiva), apoyada en las revisiones existentes y con una taxonomía propia, que separe los factores metodológicos de la evaluación de los factores propios de la naturaleza del sistema (WP1, Paper 1).

3. **Cuantificar el efecto observado de cada factor** sobre el rendimiento en un diseño experimental controlado sobre los bancos públicos, y derivar de ahí un protocolo de evaluación realista de despliegue (WP2, Paper 2).

4. **Diseñar y evaluar un detector por ruptura de asociaciones condicionado al régimen operativo**, y contrastar su robustez frente a la deriva contra baselines, sin recurrir a la selección de umbral con oráculo, con la interpretabilidad como consecuencia del mecanismo (WP3, Paper 3).

Como hilo teórico transversal, el trabajo establece las condiciones de transferibilidad de los hallazgos de banco de pruebas a planta (incluido el contexto

operativo explícito: un modelo de información que estructure la telemetría y el papel de la ontología para plantas heterogéneas), lo que lo distingue de una tesis puramente experimental. La viabilidad de ejecución en hardware de planta se trata como una consecuencia operativa que se comprueba sobre perfiles de carga realistas, no como objetivo de la investigación.

2.2. Hipótesis

El núcleo de hipótesis se organiza en dos planos (diagnóstico y propuesta) más una consecuencia y una delimitación explícita.

Hipótesis central (explicativa, nivel tesis). La discrepancia entre el rendimiento en banco de pruebas y el esperable en despliegue real no es un artefacto aleatorio, sino el efecto de un conjunto identificable de factores: (a) factores metodológicos de la evaluación (la selección de umbral con oráculo sobre el conjunto de prueba y el ajuste por puntos); y (b) factores propios de la naturaleza del sistema (la no estacionariedad y la dependencia del régimen operativo). El efecto observado de cada factor sobre el rendimiento puede aislarse y estimarse dentro de un diseño experimental controlado. Esta hipótesis no promete resolver la brecha, sino demostrarla y medir su composición; gobierna el plano de diagnóstico (WP1 y WP2). Formulada así no se rechaza en bloque: el resultado puede ser que un factor no presente un efecto observable, y eso también es un hallazgo.

Hipótesis de trabajo (mecanismo, nivel artículo). El estado operativo de la planta es latente y se manifiesta en asociaciones estables entre las variables medidas. (a) *Contexto*: esas asociaciones dependen del régimen operativo, por lo que el criterio de normalidad debe condicionarse al régimen y no aplicarse de forma global. (b) *Mecanismo*: bajo las mismas condiciones exógenas y el mismo régimen, la evolución de las variables endógenas preserva esas asociaciones; su ruptura es un indicador de anomalía más robusto frente a la deriva que el valor individual de cada variable o que una puntuación agregada umbralizada de forma global. Esta hipótesis gobierna el plano de propuesta (WP3).

Interpretabilidad (consecuencia, no hipótesis). Si la detección opera por ruptura de asociaciones condicionada al régimen, la alarma identifica qué asociación y en qué régimen se ha roto: una explicación nativa del disparo, que describe el evento detectado sin afirmar nada sobre su causa física. La cautela es deliberada y tiene respaldo: la evidencia reciente muestra que la atribución de una alarma a variables concretas resulta inexacta justamente donde se la suponía fiable, en los actuadores categóricos (Fung et al., 2024), de modo que la explicación se entiende aquí como descripción de qué asociación se rompió, no como identificación de la causa.

Delimitación (lo que no se afirma). No se afirma reducir la brecha en una planta real concreta. Los datos de planta disponibles carecen de verdad de referencia de ataques y no permiten métricas de detección; se usan como evidencia descriptiva del problema (prueba de concepto y trabajo futuro). Conviene distinguir dos planos que la literatura suele colapsar: la representación del contexto (el estado del proceso inferido de los datos)

sí aporta información y alimenta el criterio de detección; la operacionalización de la decisión (reglas, restricciones, costes y utilidad) no es información observacional, sino el gobierno de la alarma. Las dos hipótesis son, además, excluyentes en lo que afirman: caracterizar la composición de la brecha (central) y proponer un mecanismo de detección condicionado al régimen (trabajo) pueden resultar ciertas o falsas de forma independiente, sin que una determine a la otra.

Criterio de decisión. Si, al evaluar el mecanismo propuesto con el panel de métricas realistas de despliegue, su ventaja sobre los baselines triviales desaparece tras un cambio de régimen o de banco de pruebas, el programa se reorienta hacia la robustez frente a la deriva y la transferibilidad antes que hacia la exactitud puntual; si la ventaja persiste bajo presupuesto de alarmas y bajo transferencia entre plantas, ese es el resultado publicable central.

3. Introducción y estado del tema

3.1. Justificación

La gestión eficiente y segura del agua potable es una de las grandes preocupaciones del desarrollo sostenible de las ciudades. Las estaciones de tratamiento de agua potable (ETAP) y las redes de distribución son infraestructuras críticas: su funcionamiento continuo es esencial para la salud pública. En España, el Real Decreto-ley 12/2018, de 7 de septiembre, transpone la Directiva NIS y establece obligaciones de seguridad para los operadores de servicios esenciales, entre ellos el sector del agua (Real Decreto-ley 12/2018).

La digitalización de estas infraestructuras ha transformado su gestión. La proliferación de sensores del Internet de las Cosas (IoT, del inglés *Internet of Things*), la adopción de sistemas de supervisión, control y adquisición de datos (SCADA, del inglés *Supervisory Control and Data Acquisition*) cada vez más conectados, y la convergencia de las redes de tecnología de operación (OT) con las de tecnología de la información (IT, del inglés *Information Technology*) han mejorado la eficiencia, pero también han ampliado una superficie de ataque que los sistemas de protección tradicionales no fueron diseñados para afrontar (Stouffer et al., 2023; Giraldo et al., 2018). Importa fijar desde el principio el alcance de este trabajo: la convergencia IT-OT es el contexto que explica la amenaza, pero el objeto de estudio es la **capa OT (las series temporales del proceso físico)**, no el tráfico de red ni el perímetro IT.

La amenaza ha pasado de un riesgo puntual a una campaña sostenida y respaldada por estados. El ataque a la planta de Oldsmar (Florida, 2021) ilustró su gravedad; en abril de 2020, operadores afiliados a la Guardia Revolucionaria Iraní atacaron seis instalaciones de la Autoridad del Agua de Israel con el objetivo de elevar el cloro a concentraciones peligrosas, uno de los primeros incidentes documentados con intención de causar daño físico a la población mediante un ciberataque a sistemas hídricos (Unna, 2020). Entre 2023

y 2024, el grupo CyberAv3ngers comprometió al menos 75 controladores lógicos programables (PLC, del inglés *Programmable Logic Controllers*) en varios países, incluidos 34 sistemas de agua en Estados Unidos (CISA, 2023). Según datos recogidos por la Oficina de Fiscalización del Gobierno estadounidense, más del 70 % de los sistemas de agua inspeccionados incumple requisitos básicos de evaluación de riesgos y resiliencia (U.S. GAO, 2024).

Frente a esta situación, la respuesta regulatoria europea ha dejado de ser una recomendación para convertirse en una obligación exigible. La Directiva (UE) 2022/2555 (NIS2), que deroga y refuerza la Directiva NIS, clasifica el suministro de agua potable y las aguas residuales como sectores esenciales (Directiva NIS2, 2022). A las entidades esenciales les impone medidas de gestión de riesgos, entre ellas la detección y el tratamiento de incidentes (art. 21), y la notificación obligatoria de todo incidente significativo en plazos estrictos: alerta temprana en 24 horas, notificación en 72 horas e informe final en un mes (art. 23). Estas obligaciones presuponen una capacidad de detección fiable y casi en tiempo real (no puede notificarse en 24 horas lo que no se ha detectado), respaldada por la responsabilidad de los órganos de dirección y por sanciones de hasta 10 millones de euros o el 2 % de la facturación mundial anual. En España, la transposición de la NIS2 se tramita mediante la Ley de Coordinación y Gobernanza de la Ciberseguridad, cuyo anteproyecto aprobó el Consejo de Ministros en enero de 2025, una vez superado el plazo de octubre de 2024 (Consejo de Ministros, 2025). El marco europeo convierte así la detección fiable de anomalías, a la cadencia real de la planta (periodos de muestreo de segundos a un minuto en los sistemas SCADA), en una exigencia que el marco regulatorio vuelve además jurídicamente exigible.

Una revisión del estado del arte, en el contexto aplicado del proyecto TrueData, precisa dónde residen hoy las dificultades reales para llevar estos sistemas a la operación. La mayoría son operativas, ligadas al despliegue en planta; dos son de fondo, conceptuales: no existe una definición de anomalía independiente del contexto operativo (lo anómalo en un régimen puede ser normal en otro), y distinguir un fallo de un ataque deliberado solo a partir de las señales es difícil. A ellas se suma un problema metodológico documentado, que esta investigación coloca en el centro: fijar el umbral de detección mediante **selección de umbral con oráculo sobre el conjunto de prueba** (*best-F1 / oracle thresholding*) y aplicar el **ajuste por puntos** (*point adjustment*) eleva e iguala de forma artificial los resultados publicados y oculta las diferencias reales entre métodos (Wu & Keogh, 2023; Kim et al., 2022; Garg et al., 2021); ambas prácticas se detallan en la sección 3.4. Una evaluación que controle estos factores precede, por tanto, a cualquier afirmación de fiabilidad: la selección de umbral con oráculo muestra el potencial del modelo, pero no es aplicable en producción, donde no se dispone de las etiquetas para calibrarlo. La literatura sugiere que aún no se ha consolidado un marco común para fijar el umbral sin ese oráculo en operación, y esa carencia es uno de los huecos que el trabajo aborda.

La segunda dificultad de fondo es la robustez frente a la deriva (del inglés *drift*): las infraestructuras hídricas son no estacionarias (varían con la estación, la demanda y el modo de operación), de modo que un modelo entrenado sobre un rango temporal u operativo determinado se degrada cuando la distribución se desplaza entre la validación y la operación (Lv et al., 2023; Zamanzadeh Darban et al., 2024). La tercera es la explicabilidad de las alarmas: en operación, un detector que solo señala «anomalía» sin indicar qué variable y qué evento la disparan deja al operador sin información accionable (Zamanzadeh Darban et al., 2024). La cuarta, transversal, es la adquisición y estructuración del contexto operativo (el estado del proceso, las relaciones físicas y la semántica de la planta), sustrato que permite condicionar el criterio de alarma al régimen, ganar robustez frente a la deriva y construir explicaciones útiles.

Estas dificultades comparten un mismo sustrato conceptual, ampliamente asumido en la literatura. La planta puede entenderse como un sistema dinámico multivariante parcialmente observado, descrito en un espacio de estados: un estado interno latente (que incluye el régimen de operación) evoluciona gobernado por la física y por la lógica de control, y los sensores solo captan de él una proyección ruidosa (Kalman, 1960). Conviene distinguir las variables **exógenas**, externas a la planta (la demanda, las condiciones ambientales, las consignas externas, la calidad del agua de entrada), que introducen la estocasticidad, de las variables **endógenas**, internas a la dinámica del proceso (el estado y sus relaciones físicas, materializadas en el lazo de control y sus actuadores). Bajo las mismas condiciones exógenas, el mismo proceso y el mismo régimen, las **asociaciones entre las variables endógenas se mantienen**: lo reproducible es la lógica de relación entre variables, no la trayectoria física completa, que el ruido, los retardos hidráulicos y los lazos de control hacen irrepetible. Esta estabilidad de las asociaciones, y no una supuesta regularidad de la trayectoria, es la que habilita una detección entrenada solo sobre operación normal: detectar equivale a estimar ese estado y vigilar la ruptura de las asociaciones esperadas, principio de la detección de fallos basada en modelo (Gao et al., 2015), con la particularidad de que aquí el modelo se aprende de los datos cuando no se dispone de ecuaciones de primeros principios (Li et al., 2023; Billings, 2013). Las revisiones recientes coinciden en que las distintas familias de detección modelan, con distinto sesgo inductivo, esa misma normalidad del proceso (Zamanzadeh Darban et al., 2024; Alves et al., 2026). Desde esta lectura común, la deriva es la aparición de regímenes o transiciones no representados en el entrenamiento; la explicabilidad nace de señalar la asociación y el régimen que se quiebran; y la estructuración del contexto es el conocimiento previo que delimita ese espacio de estados.

Las cuatro dificultades no son, por tanto, problemas independientes, sino manifestaciones de una misma brecha entre el rendimiento en banco de pruebas y la utilidad operativa de la detección. La pregunta que organiza esta investigación es por qué se produce esa brecha y qué la compone: qué parte se debe a factores metodológicos de la evaluación (la selección de umbral con oráculo y el ajuste por puntos) y qué parte a la

naturaleza no estacionaria y dependiente del régimen del propio sistema. La deriva, la explicabilidad y la estructuración del contexto pasan a ser dimensiones donde puede residir la brecha, no líneas a ejecutar en paralelo. El estado del tema se organiza en seis bloques: el dominio hídrico y su ciberseguridad (3.2); las familias de técnicas de IA para la detección sobre series OT (3.3); la detección fiable y su evaluación realista de despliegue (3.4); la deriva, el contexto operativo y la robustez (3.5); la explicabilidad como consecuencia de la detección (3.6); y la estructuración del contexto y su transferibilidad (3.7).

3.2. Infraestructuras hídricas críticas y su ciberseguridad

Las infraestructuras de tratamiento y distribución de agua potable son uno de los sectores esenciales de la Directiva NIS2 (Directiva NIS2, 2022). Dependen de sistemas de control industrial compuestos por PLC, sistemas SCADA, unidades terminales remotas (RTU), interfaces hombre-máquina (HMI) y redes de sensores y actuadores, que supervisan y controlan el proceso físico en tiempo real (Stouffer et al., 2023). Para situar con precisión el objeto de estudio conviene recurrir al modelo de referencia de Purdue, que estratifica un ICS en niveles: el proceso físico y la instrumentación (niveles 0-1), el control (PLC/RTU, nivel 2 inferior) y la supervisión (SCADA/HMI, nivel 2 superior), por encima de los cuales se sitúan las capas de operaciones de fabricación e IT corporativa (niveles 3-5). **Este trabajo opera en los niveles 0 a 2 (el proceso, su control y su supervisión) y toma como objeto las series temporales de la telemetría del proceso físico, no los protocolos industriales, el tráfico de red ni la capa IT.** La detección que aquí se estudia observa el comportamiento del proceso, no la red que lo transporta.

La convergencia de las redes OT con las de IT ha ampliado la superficie de ataque de unos sistemas concebidos para operar aislados (Giraldo et al., 2018); el detector que aquí se estudia, sin embargo, vigila el proceso físico y complementa (no sustituye) la seguridad perimetral. El ataque ya citado a la planta de Oldsmar y los escenarios reproducidos en los bancos de pruebas SWaT (*Secure Water Treatment*) y WADI (*Water Distribution*) del iTrust Centre de la Universidad de Tecnología y Diseño de Singapur (SUTD) (Lemos, 2021; Goh et al., 2017) muestran la necesidad de detección a nivel de proceso. La ciberseguridad hídrica adquiere, además, una dimensión estratégica en regiones dependientes de la desalación: la región de Oriente Medio y Norte de África produce el 41,8 % del agua desalada mundial, y países como Kuwait, Qatar o Bahréin obtienen más del 90 % de su agua potable por desalación, con reservas de apenas uno a cinco días (Anadolu Agency, 2025). El impacto de un misil sobre la desaladora Doha West de Kuwait en marzo de 2026, que afectó a cerca del 38,5 % de la capacidad de agua dulce del país (The National, 2026), y el programa malicioso IOCONTROL, descubierto en 2024 para comprometer dispositivos OT en infraestructuras críticas (Claroty Team82, 2024), confirman que la infraestructura hídrica es ya un objetivo sistemático, físico y cibernético.

3.3. Técnicas de inteligencia artificial para la detección de anomalías en series OT

La detección de anomalías sobre series OT plantea desafíos propios: los procesos físicos son deterministas en su lógica, pero esa lógica depende del régimen operativo, de modo que las relaciones entre variables cambian según el modo de funcionamiento de la planta (Goh et al., 2017). El marco de partida es la detección de anomalías en series temporales multivariantes (MTSAD, del inglés *Multivariate Time-Series Anomaly Detection*) sobre la telemetría del proceso. La heterogeneidad de los tipos de señal (variables continuas, discretas multinivel y binarias) cuenta ya con detectores conscientes del tipo de señal (Zhan et al., 2024; Alnegheimish et al., 2025; Li et al., 2025); más que un reto abierto, es una palanca que esta investigación incorpora de forma transversal: modelar por separado los patrones de los sensores y las reglas de los actuadores reduce la proporción de ataques no detectados (Cai et al., 2024). La revisión se centra, pues, en las familias de técnicas y en sus implicaciones para el despliegue.

Métodos basados en reglas invariantes. Aprenden restricciones físicas, lógicas o temporales propias de la operación normal (por ejemplo, «si la bomba está activa, el caudal supera un mínimo») y señalan anomalía cuando se incumplen. La literatura distingue invariantes derivadas del diseño del proceso (Feng et al., 2019; Adepu & Mathur, 2021), enfoques centrados en datos mediante minería de reglas de asociación (Pal et al., 2017) e híbridos que combinan ambos (Umer et al., 2020; Raman & Mathur, 2022a). Aportan alta interpretabilidad y bajo coste de inferencia, pero tienen un techo conocido frente a los ataques sigilosos: AICrit alcanza cero falsos positivos pero detecta solo 24 de los 36 escenarios de ataque de SWaT, al no dispararse ante manipulaciones de baja magnitud (Raman & Mathur, 2022b). Reconocer ese techo es parte del diagnóstico de la brecha.

Modelos de predicción de series temporales. Aprenden el comportamiento esperado de cada variable y señalan anomalía cuando la desviación respecto a la predicción supera un umbral. Las arquitecturas van de las redes de memoria a corto y largo plazo (LSTM, del inglés *Long Short-Term Memory*) y sus variantes codificador-decodificador con atención (Sutskever et al., 2014; Vaswani et al., 2017) a los modelos basados en *Transformers*. En la frontera clásica, métodos como Isolation Forest (Liu et al., 2008) ofrecen líneas base competitivas a un coste muy inferior; de hecho, bancos de pruebas recientes muestran que los detectores clásicos bien ajustados igualan o superan a los modelos profundos en muchos escenarios (Wu & Keogh, 2023). El coste de inferencia varía con la arquitectura, factor relevante para la operación en tiempo real.

Métodos basados en reconstrucción. Los autocodificadores (AE, del inglés *AutoEncoders*) y sus variantes variacionales y adversariales aprenden una representación compacta de los datos normales y usan el error de reconstrucción como puntuación de anomalía (Audibert et al., 2020; Su et al., 2019; Tuli et al., 2022). Comparten dos limitaciones operativas: la puntuación depende de la hipótesis sobre la distribución del error (típicamente gaussiana) y su alcance queda acotado por la ventana temporal observada, de modo que pierden anomalías cuya huella sea pequeña frente a la ventana;

además, pueden reconstruir bien las propias anomalías y dejarlas pasar. Esta fragilidad se ha demostrado de forma adversarial: manipulando solo 4 de 82 sensores en WADI, la exhaustividad de un detector por reconstrucción cae de 0,68 a 0,12 (Erba et al., 2020), evidencia directa de la brecha entre el rendimiento nominal y el comportamiento bajo condiciones realistas.

Modelos de regresión transversal y basados en grafos. Los primeros predicen cada variable a partir del estado del resto en el mismo instante y capturan relaciones entre sensores sin una estructura explícita (Chen et al., 2021). Los modelos de grafos (GNN, del inglés *Graph Neural Networks*) representan esas relaciones como aristas, predefinidas a partir del proceso, aprendidas de extremo a extremo o inferidas (Deng & Hooi, 2021; Wu et al., 2020; Zhao et al., 2020); ganan expresividad para las anomalías entre variables a costa de un mayor coste de inferencia (Zhou et al., 2024). Una línea reciente enriquece estos grafos con estructura causal para ganar robustez frente a los cambios de distribución (Koutroulis et al., 2023; Malarkkan et al., 2025); este trabajo dialoga con esa dirección desde la especificidad del dominio hídrico, tratando la atribución como descripción de qué asociación se rompe y no como afirmación causal.

Fusión de resultados. Combinar las puntuaciones de varias familias, sensores y niveles en una medida unificada es un problema abierto, con estrategias que van de reglas simples (máximo, media, votación) a agregaciones que modelan la dependencia entre residuos, como la distancia de Mahalanobis (De Maesschalck et al., 2000), o que aprenden su distribución conjunta (Rezende & Mohamed, 2015). La regla de fusión condiciona la sensibilidad y la tasa de falsos positivos del sistema integrado.

En el fondo, todas estas familias persiguen lo mismo (aprender la normalidad del proceso) y se diferencian en el sesgo inductivo con que la aproximan: dependencias temporales, una estructura de grafo de influencias, restricciones mecanicistas por estado o la reconstrucción de lo normal. Son lecturas parciales del mismo sistema dinámico parcialmente observado (Zamanzadeh Darban et al., 2024; Alves et al., 2026).

3.4. Detección fiable y evaluación realista de despliegue

La adopción en planta exige no solo exactitud, sino fiabilidad demostrable. La literatura del dominio documenta sesgos metodológicos sistemáticos en los bancos de pruebas dominantes (SWaT, WADI y BATADAL). La **selección de umbral con oráculo sobre el conjunto de prueba** (fijar el umbral con las etiquetas de prueba para maximizar la métrica, una práctica no replicable en producción) y el **ajuste por puntos** (dar por detectado un intervalo entero porque un único punto cae cerca de la anomalía) inflan las métricas: como casi cualquier método acierta al menos un punto de cada intervalo, las puntuaciones se saturan y dejan de distinguir los métodos buenos de los mediocres (Wu & Keogh, 2023; Kim et al., 2022; Garg et al., 2021). A ello se añade la no generalización del umbral por el desplazamiento temporal de la distribución entre validación y prueba (Lv et al., 2023). Esta crítica metodológica, cada vez más aceptada, ha impulsado métricas

sensibles a la estructura temporal, el volumen bajo la superficie (Paparrizos et al., 2022) y las métricas de afiliación (Huet et al., 2022), y marcos de evaluación unificados (Qiu et al., 2025). Que la práctica aún no esté consolidada lo sugiere el hecho de que los estudios del área empleen en promedio en torno a 1,3 conjuntos de datos por artículo (Lamberts et al., 2023); a ello se añade la inconsistencia de los resultados de un mismo método al cambiar de conjunto de datos, documentada en evaluaciones comprehensivas (Fung et al., 2022). Algunos trabajos llevan ya la evaluación al terreno operativo del propio dominio, midiendo los detectores bajo un presupuesto de alarmas y reportando la proporción de incidentes no detectados y el retardo de detección sobre SWaT y WADI (Heydari & Nyarko, 2026); esta investigación construye sobre esa evaluación, no la reclama como propia.

La operación en tiempo real refuerza la exigencia. SWaT muestrea a 1 Hz (Mathur & Tippenhauer, 2016), mientras que las plantas reales presentan periodos mayores y variables, lo que fija una latencia admisible de segundos; y una tasa alta de falsos positivos resulta inasumible para un centro de control. De ahí que el trabajo adopte un panel de evaluación que reporte siempre, además de la exactitud, métricas sensibles a la estructura temporal y al coste operativo: volumen bajo la superficie de la curva precisión-exhaustividad (VUS-PR), métricas de afiliación, una F-compuesta por eventos y la evaluación bajo presupuesto de alarmas, junto con baselines triviales (un detector aleatorio y uno que marca todo como positivo) como prueba de cordura (Garg et al., 2021; Kim et al., 2022). Este panel precede y condiciona las afirmaciones de fiabilidad que se hagan en este trabajo.

3.5. Deriva, contexto operativo y robustez

La detección sobre series OT exige una noción de anomalía que las taxonomías genéricas suelen pasar por alto: la anomalía no es absoluta, sino dependiente del contexto operativo. Una misma presión puede ser normal en régimen de llenado y anómala en mantenimiento, sin que cambie su valor instantáneo. Zamanzadeh Darban et al. (2024) distinguen, por comportamiento, anomalías globales, contextuales, estacionales y entre variables; en infraestructuras hídricas predominan las contextuales y las estacionales, lo que desaconseja los detectores que umbralizan de forma global una única puntuación agregada. A ese eje conviene añadir el de la intención: la mayoría de las anomalías estudiadas históricamente eran fallos no intencionados, mientras que los ciberataques introducen una anomalía adversarial, provocada por una inteligencia que elige qué variables del proceso manipular y, a veces, enmascara la manipulación para que parezca normal, en el banco SWaT, ataques de una o varias etapas sobre uno o varios puntos (SSSP, SSMP, MSSP, MSMP) (Goh et al., 2017), lo que exige distinguir un fallo de un ataque deliberado (Giraldo et al., 2018) y refuerza la necesidad de una detección consciente del estado del proceso y de las relaciones entre variables (Chandola et al., 2009).

Una línea creciente atiende esta dependencia con detectores conscientes del estado del proceso. Ghaeini et al. (2018) introducen invariantes condicionadas al régimen, y

Raman y Mathur integran el conocimiento del proceso en un marco híbrido de física y datos (Raman & Mathur, 2022a). Los procesos industriales tienden, además, a presentar localidad temporal (es probable permanecer en el mismo régimen entre instantes consecutivos), lo que, según la literatura sugiere, convierte a las máquinas de estados finitos, los modelos de Markov ocultos y los modelos de espacio de estados en líneas base a considerar cuando importan la interpretabilidad y el coste (Wei et al., 2024; Barakat et al., 2025).

Sobre este sustrato, el principal reto de robustez es la deriva. Los sistemas reales son no estacionarios y los modelos entrenados fuera de línea se degradan en producción; la deriva no es uniforme, se distingue entre súbita, gradual, incremental y recurrente (Gama et al., 2014; Lu et al., 2019), y en infraestructuras hídricas conviven la recurrente (estacional) con la gradual (envejecimiento de sensores y actuadores). En los detectores semisupervisados, entrenados solo sobre operación normal, la deriva determinante es la de la propia normalidad (del inglés *normality shift*), señalada como poco explorada frente a la deriva de los patrones anómalos (Han et al., 2023); su efecto es una degradación progresiva que ha motivado detectores sensibles al propio rendimiento del modelo (Bayram et al., 2022). Conviene precisar el origen de esta evidencia: el estudio de la *normality shift* procede mayoritariamente de la detección de intrusiones en red y del análisis de registros, no de las series OT de proceso; aquí se asume **trasladable** a la telemetría del agua, extrapolación que esta investigación se propone verificar y no da por demostrada en el dominio hídrico. Caracterizar la deriva en este dominio y explorar mecanismos de adaptación sin reentrenamiento costoso es una de las líneas centrales del trabajo. Conviene además distinguir la ventana del ataque de la ventana de la anomalía observada: una manipulación puntual puede prolongarse por propagación aguas abajo (retardos hidráulicos) y aguas arriba (reacción de los lazos de control), lo que condiciona el campo receptivo y la ventana de análisis del detector.

3.6. La explicabilidad como consecuencia de la detección

En operación, una alarma sin explicación es poco accionable: el operador necesita saber dónde se origina la anomalía, de qué tipo es y qué elementos del proceso intervienen para responder con rapidez y proporción. La literatura reciente señala que la explicación de qué variable y qué evento disparan cada anomalía ha recibido menos atención que la exactitud (Zamanzadeh Darban et al., 2024). En el enfoque de esta tesis, la interpretabilidad no es una hipótesis ni un módulo añadido, sino una **consecuencia** del mecanismo de detección: si la alarma se dispara por la ruptura de una asociación condicionada al régimen, identifica de forma nativa qué asociación y en qué régimen se ha roto.

La inferencia de dependencias entre variables, los valores SHAP (Lundberg & Lee, 2017), la información mutua, la causalidad de Granger o el descubrimiento causal (Runge et al., 2019), aproxima la estructura funcional del proceso y atribuye cada alarma a las

variables responsables, pero asume supuestos (linealidad, estacionariedad) que los ICS no siempre cumplen; inferir la estructura en un sistema que cambia de régimen puede producir relaciones espurias que disparen falsos positivos, lo que motiva aprenderla por modo o condicionar al estado y al régimen. La atribución por valores de Shapley adaptada a series temporales lleva esta idea a la práctica (Franco de la Peña et al., 2025), y se han propuesto esquemas de explicación específicos para sistemas hídricos (Mathuros et al., 2024) y métodos en línea basados en descubrimiento causal (Meli, 2024). Ahora bien, un estudio sistemático advierte que la atribución de la alarma falla con más frecuencia sobre los actuadores categóricos (Fung et al., 2024): de ahí que aquí la explicación se entienda como descripción de qué asociación se rompió (un *proxy* del evento), no como identificación de su causa física, y que su fiabilidad se trate como objeto de verificación a nivel de ventana de ataque, no como propiedad garantizada. La generación de explicaciones en lenguaje natural mediante modelos de lenguaje queda apuntada como posible trabajo futuro, fuera del alcance central.

3.7. Estructuración del contexto y transferibilidad

Condicionar la detección al régimen y explicar las alarmas requiere estructurar el contexto operativo. Conviene separar dos artefactos con papeles distintos. El primero es el **modelo de información**: un sustrato operativo, ligero y fuera de línea, que estructura la telemetría, asocia cada variable a su proceso o subsistema y define el régimen, fijando el sesgo inductivo del detector (qué adyacencia usa un modelo de grafo, qué regímenes parametrizan una máquina de estados). El estándar ISA-95 (IEC 62264) ofrece una jerarquía de referencia para la información de planta (empresa, planta, área, unidad, equipo, sensor/actuador) adecuada para ese papel (ISA-95/IEC 62264). Este modelo de información se emplea como conocimiento previo, no como un razonador que se ejecute en el lazo de inferencia: el modelo embebido ejecuta solo operaciones tensoriales rápidas cuyo sesgo ya viene dictado por la estructura.

El segundo artefacto es la **ontología**, situada en un plano diferente: el de la transferencia y la interoperabilidad. Su papel no es detectar, sino permitir que el método no dependa de la nomenclatura ni de las etiquetas de una planta concreta y mapear la semántica entre plantas heterogéneas (por ejemplo, entre SWaT y una planta real), en la línea del problema de interoperabilidad entre sistemas industriales heterogéneos (Givehchi et al., 2017). Las ontologías SSN/SOSA del W3C aportan un vocabulario común para sensores, observaciones y actuadores (Haller et al., 2019), y las revisiones recientes documentan la fragmentación del panorama ontológico y la escasa cobertura del sector hídrico (Karabulut et al., 2023; Jarwar et al., 2025). El respaldo de esta vía en el dominio del agua es débil e indirecto: se enmarca, por tanto, como horizonte de interoperabilidad y posible trabajo futuro, sin atribuirle capacidad de detección. Modelo de información y ontología no compiten (el primero responde a «cómo lo implemento ahora», la segunda a «cómo se generaliza») y constituyen el contexto operativo explícito que vertebra el hilo teórico de transferibilidad.

La ejecución de la inferencia en hardware de planta, con recursos limitados y restricciones de latencia, se trata como una consecuencia operativa que se comprueba sobre perfiles de carga realistas (no como objeto de estudio): cuando un modelo lo exige, las técnicas de compresión y los motores de inferencia permiten alcanzar latencias operativas (Zhou et al., 2024), y su caracterización se reserva como comprobación, no como objetivo de la investigación.

4. Metodología y plan de trabajo

4.1. Marco metodológico

Como marco general se adopta la investigación en ciencias del diseño (DSR, del inglés *Design Science Research*) (Hevner et al., 2004; Peffers et al., 2007), adecuada para una investigación que construye y evalúa artefactos (un protocolo de evaluación, un método de cuantificación de factores y un detector) para responder a un problema real. Sus tres ciclos (Hevner, 2007) organizan el trabajo: el de relevancia lo conecta con el dominio hídrico y sus requisitos operativos; el de rigor, con la base de conocimiento (literatura de detección, de evaluación y de modelado); y el de diseño concentra la construcción y la evaluación iterativa.

Para garantizar que la aportación es de conocimiento y no un mero desarrollo, la tesis se sitúa en el marco de contribución de Gregor y Hevner (2013), en el cuadrante de exaptación: extender técnicas de detección relativamente maduras a un dominio y unas restricciones poco explorados (las series OT del proceso de agua y las condiciones de despliegue), donde el trasplante no es trivial porque las condiciones del dominio (latencia, deriva de los sensores, dependencia del régimen) obligan a adaptaciones de las que se espera derivar conocimiento de diseño. El objetivo es una contribución de nivel intermedio, un conjunto de principios de diseño que el programa busca validar empíricamente bajo el diseño considerado; los artefactos construidos, constructos, modelos y métodos, en los términos de March y Smith (1995), son el vehículo de la evaluación, no el fin. No se fija una arquitectura definitiva: la que el programa priorice dependerá del diagnóstico de la brecha.

El ciclo de diseño se ejecuta mediante un bucle experimental reproducible que se repite sobre cada hipótesis: (1) formular una hipótesis falsable con un criterio de éxito verificable; (2) implementarla con un flujo *notebook-first*, promocionando a código con pruebas lo que demuestra valor; (3) evaluarla bajo el panel de la sección 4.2 sobre los conjuntos de referencia; (4) compararla con baselines y con otras familias en igualdad de condiciones; (5) cristalizar el hallazgo (o descartarlo de forma trazable); y (6) realimentar la revisión bibliográfica y el diseño del siguiente experimento.

La cuantificación de la brecha (WP2) se articula sobre un **diseño experimental controlado**. Sobre el panel de evaluación y los conjuntos de referencia, se comparan configuraciones que activan o desactivan cada factor de forma cruzada y a capacidad del

modelo controlada, de modo que el efecto observado de cada uno se estime por separado y se distinga del de los demás. Los factores son los de la hipótesis central: los metodológicos de la evaluación (la selección de umbral con oráculo sobre el conjunto de prueba y el ajuste por puntos) y los propios del sistema (la no estacionariedad, aproximada por la generalización temporal intra-planta, y la dependencia del régimen, aproximada por el condicionamiento del criterio de normalidad). El protocolo declara qué componentes se mantienen fijos y cuáles se reoptimizan en cada configuración, de modo que los efectos se interpretan como **observados dentro del diseño y condicionales al pipeline fijado, no como efectos causales puros**; el análisis emplea un modelo con término de interacción, y si dos factores se solapan, esa redundancia es en sí un resultado. La estrategia de evaluación se articula con el marco FEDS (Venable et al., 2016): evaluación formativa en entorno artificial durante el desarrollo y evaluación sumativa sobre los bancos públicos, con baselines reproducidos en igualdad de condiciones, múltiples semillas y análisis de significancia, sobre más de un conjunto de datos y más de una métrica (Lamberts et al., 2023). En consecuencia, el banco de pruebas demuestra **eficacia** (que el efecto observado se debe al artefacto), no efectividad en operación real; la evaluación naturalista, con despliegue en planta y operador en el lazo, se reconoce como frontera pendiente y trabajo futuro.

4.2. Diseño experimental y panel de evaluación

Conjuntos de datos. La base experimental son los conjuntos públicos y etiquetados de referencia del dominio: SWaT y WADI, del iTrust Centre de la SUTD (Lemos, 2021; Goh et al., 2017; Mathur & Tippenhauer, 2016), con HAI y BATADAL como extensiones para contrastar procesos y topologías distintas. El uso exclusivo de datos públicos favorece la reproducibilidad y la comparabilidad con la literatura. Ante la ausencia de datos de planta real etiquetados (sin los cuales la detección no es medible), el salto entre entrenamiento y operación se aproxima por dos vías: la principal es la generalización temporal dentro de una misma planta (entrenar en un periodo y evaluar en otro posterior), que reproduce la deriva entre entrenamiento y operación sin alterar la física del proceso; la transferencia entre bancos de distinto tipo (SWaT, de tratamiento, frente a WADI, de distribución) no se plantea como transferencia de pesos (que fracasaría por el cambio de proceso, no por la calidad del modelo), sino como prueba de si el método generaliza de forma agnóstica al proceso, reentrenando sobre la operación normal de cada planta.

Diseño del estudio y variables. El estudio es cuasi-experimental, con evaluación retrospectiva sobre datasets públicos validados y generalización temporal intra-planta como aproximación a la deriva. Las **variables independientes** son la familia y la capacidad del modelo (controladas), la activación de la representación del contexto y del régimen, y el estado de cada factor de la brecha (selección de umbral con oráculo *activada/desactivada*, ajuste por puntos *activado/desactivado*, condición temporal y régimen). Las **variables dependientes** son las métricas del panel (volumen bajo la superficie, métricas de afiliación, F-compuesta por eventos, comportamiento bajo

presupuesto de alarmas, retardo de detección y tasa de falsos positivos). Se **controlan** el dataset, las particiones, el hardware y las semillas, y se **neutralizan como variables de confusión** la selección de umbral con oráculo, la normalización ajustada sobre prueba, el ajuste por puntos y el solape de ventana. La distinción entre variables exógenas (externas a la planta) y endógenas (internas a la dinámica del proceso) estructura la representación, sin confundirse con el par sensor/actuador, que designa el tipo de señal.

Panel de evaluación. Constituye el eje metodológico y la principal exigencia de rigor. Toda comparación fija el umbral **sin recurrir al oráculo del conjunto de prueba**, prescinde del ajuste por puntos, emplea validación cruzada de avance temporal y reporta siempre el panel: volumen bajo la superficie de la curva precisión-exhaustividad (VUS-PR), métricas de afiliación, F-compuesta por eventos (Fc1) y evaluación bajo presupuesto de alarmas, además del retardo de detección y la tasa de falsos positivos (Paparrizos et al., 2022; Huet et al., 2022; Garg et al., 2021; Heydari & Nyarko, 2026). Se incluyen baselines triviales (un detector aleatorio y uno que marca todo como positivo) como prueba de cordura: ninguna métrica que un baseline trivial iguale puede sostener una afirmación de mérito (Kim et al., 2022). Este panel precede y condiciona cualquier afirmación de fiabilidad de este trabajo.

Familias comparadas. Se comparan en igualdad de condiciones baselines clásicos como Isolation Forest (Liu et al., 2008), modelos de predicción basados en LSTM y *Transformers* (Sutskever et al., 2014; Vaswani et al., 2017), de reconstrucción (Audibert et al., 2020; Su et al., 2019; Tuli et al., 2022), de grafos (Chen et al., 2021; Deng & Hooi, 2021; Zhao et al., 2020) y de reglas invariantes (Feng et al., 2019; Umer et al., 2020; Raman & Mathur, 2022a), de modo que se cubran los distintos sesgos inductivos con que cada familia modela la normalidad.

Reproducibilidad y amenazas a la validez. El desarrollo sigue un flujo *notebook-first*; el entorno se empaqueta en contenedores y el código y los resultados se publican como artefacto citable. La validez interna se protege fijando el umbral y la normalización sin oráculo del conjunto de prueba y prescindiendo del ajuste por puntos; la de constructo, reportando métricas sensibles a la estructura temporal y al coste de alarmas, entendidas como *proxies* de utilidad operativa y no como medidas directas del comportamiento humano; la externa se acota reconociendo que los testbeds son muestras por conveniencia y evaluando la generalización entre bancos; y la de conclusión se refuerza con el diseño controlado, que separa los efectos de cada factor y su interacción. La validez de construcción del *proxy* operativo se argumenta de forma explícita: la generalización temporal intra-planta aproxima la deriva; el cambio de régimen, la dependencia del régimen; y el presupuesto de alarmas, la carga sobre el operador, mientras que la escala, la heterogeneidad entre plantas y la dimensión humana quedan fuera del *proxy* y se reconocen como límites del alcance.

4.3. Organización del trabajo: paquetes de trabajo e hilo teórico

El trabajo se organiza en torno a cuatro paquetes de trabajo y un hilo teórico transversal, sostenidos por dos corrientes permanentes, la revisión sistemática continua de la literatura (con gestión de referencias y notas enlazadas) y la infraestructura experimental reproducible (entornos, contenedores, control de versiones y registro de experimentos), que recorren todo el doctorado y alimentan el bucle de la sección 4.1.

WP0 — Marco conceptual (transversal, concentrado en el primer año). Fija el sustrato: estado operativo latente, asociaciones estables entre variables, distinción endógeno/exógeno, papeles diferenciados del modelo de información y de la ontología, y delimitación del alcance a las series OT en los niveles 0-2 de Purdue. Comprende la formación en sistemas de control industrial, ciberseguridad de infraestructuras críticas y técnicas de IA, la comprensión del dominio hídrico y un análisis exploratorio multinivel de los datos (caracterización de señales, regímenes y estacionariedad, con descriptores como catch22 (Lubba et al., 2019)). Salida: el marco teórico del plan.

WP1 — Diagnóstico teórico (Paper 1). Revisión propia **acotada a la brecha** (no una revisión sistemática exhaustiva), que se apoya en las revisiones existentes y aporta una taxonomía propia de los factores que separan el rendimiento en banco de pruebas de la utilidad operativa. Hipótesis central en su plano teórico. Salida: *Paper 1 — revisión acotada a la brecha*; cierre: taxonomía de la brecha y de sus huecos.

WP2 — Diagnóstico empírico (Paper 2). Cuantifica el efecto observado de cada factor sobre el rendimiento en el diseño controlado de la sección 4.1, sobre los bancos públicos. Hipótesis central en su plano empírico. Salida: *Paper 2 — caracterización experimental*; cierre: magnitud de cada efecto y un protocolo de evaluación realista de despliegue derivado de él.

WP3 — Propuesta (Paper 3). Diseña y evalúa un detector por ruptura de asociaciones condicionado al régimen, usando el protocolo de WP2. Hipótesis de trabajo. Salida: *Paper 3 — propuesta metodológica*; cierre: robustez frente a la deriva contra baselines, sin selección de umbral con oráculo, con interpretabilidad emergente del mecanismo.

Hilo teórico transversal. Establece las condiciones de transferibilidad de banco de pruebas a planta e incorpora el contexto operativo explícito (el modelo de información que estructura la telemetría y el papel de la ontología para plantas heterogéneas). Su respaldo en el dominio del agua es débil, por lo que se trata con prudencia, como aportación teórica y no como pieza con grandes promesas. Salida: una sección de la tesis o un artículo de posición ligero, que la distingue de una tesis puramente experimental.

El orden es WP1 → WP2 → WP3, con **WP2 y WP3 solapados**: el protocolo derivado de WP2 alimenta la evaluación de WP3. El panel de evaluación de la sección 4.2 es transversal a WP2 y WP3. El compromiso es de tres artículos más el marco teórico transversal ligero; la viabilidad de despliegue en hardware acompaña a WP3 como comprobación operativa, no como línea independiente. La redacción y difusión es una

actividad continua desde el segundo año, que articula las publicaciones de una posible tesis por compendio y la memoria final.

4.4. Cronograma y duración prevista

El doctorado se plantea para cuatro años a tiempo completo. El cronograma refleja la naturaleza paralela del trabajo: las dos corrientes transversales y la redacción ocupan barras continuas; WP0 se concentra al inicio pero realimenta a las líneas posteriores; y WP2 y WP3 se solapan ampliamente a lo largo de los años segundo y tercero, sin un orden estricto entre ellos.

TAREAS	AÑO 1				AÑO 2				AÑO 3				AÑO 4			
	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4
Corriente A: Revisión sistemática continua																
Corriente B: Infraestructura experimental reproducible																
WP0: Marco conceptual (fundamentos, dominio y datos)																
WP1: Diagnóstico teórico — revisión acotada (Paper 1)																
WP2: Diagnóstico empírico — caracterización (Paper 2)																
WP3: Propuesta — detector régimen-condicionado (Paper 3)																
Hilo teórico: transferibilidad y contexto operativo																
Viabilidad de despliegue (comprobación operativa)																
Redacción y difusión																
Integración y memoria final																

La granularidad fina por trimestre se ajustará al maquetar; lo esencial es que las barras de WP2 y WP3 se solapen y que las corrientes transversales sean continuas. Todas las tareas las ejecuta el doctorando bajo la supervisión continua de los directores; las corrientes transversales y la comprobación de viabilidad se apoyan, además, en los recursos y el personal del grupo de investigación GRITA y en el contexto del proyecto TrueData.

4.5. Instalaciones, instrumentos y técnicas disponibles

La investigación se desarrollaría en las instalaciones de la UCAM, en el grupo de investigación GRITA, que reúne la infraestructura necesaria. En cómputo se dispone de servidores con unidades de procesamiento gráfico (GPU) NVIDIA, accesibles por VPN/SSH, para entrenar los modelos, y de hardware representativo del de planta para las comprobaciones de viabilidad de inferencia. En datos, la base experimental son los conjuntos de referencia SWaT y WADI del iTrust Centre de la SUTD. El proyecto TrueData (INCIBE), origen de esta línea, aporta el contexto aplicado y el conocimiento del dominio, pero no datos de operación etiquetados; la obtención de datos de plantas reales se

plantea como una vía deseable, condicionada a acuerdos con operadores, cuya principal dificultad no es solo el acceso sino la ausencia de verdad de referencia, sin la cual la detección no es medible (Dong et al., 2023). Por ello la base experimental se apoya en los bancos públicos etiquetados.

El trabajo se apoya en el ecosistema de código abierto de Python, que favorece la reproducibilidad y una eventual transferencia al sector: PyTorch para el aprendizaje profundo; scikit-learn y statsmodels para los baselines clásicos y los modelos estadísticos de series temporales; y bibliotecas especializadas como sktime para la detección de cambios y de anomalías. La evaluación emplea implementaciones de referencia de las métricas del panel (afiliación, volumen bajo la superficie, F-compuesta por eventos, presupuesto de alarmas). En la adquisición y gestión de datos, la infraestructura del grupo se apoya en la plataforma ThingsBoard (edición comunitaria), con empaquetado en contenedores Docker multiarquitectura (ThingsBoard, s.f.); la gestión bibliográfica y de notas se realiza con Zotero y Obsidian, con apoyo de herramientas de descubrimiento de literatura.

5. Posicionamiento frente al estado del arte

Varios trabajos recientes cubren piezas sueltas de lo que esta tesis propone. La contribución no reside en ninguna de esas piezas por separado, sino en su **integración** y en su aplicación específica a las series OT del proceso de agua (niveles 0-2 de Purdue). Conviene posicionarse con precisión frente a cada uno.

Trabajo	Qué aporta ya	Cómo se diferencia esta tesis
Heydari & Nyarko (2026)	Evaluación bajo presupuesto de alarmas a nivel de evento en SWaT/WADI; los <i>rankings</i> se invierten bajo la restricción de carga del operador.	No se reclama la evaluación realista como novedad: se construye sobre ella y se integra en el panel de la sección 4.2.
Cai et al. (2024)	Separa sensores y actuadores en la dependencia espaciotemporal (método SA ²).	Se diferencia por la condicionalidad explícita al régimen y la adaptación a la deriva, no solo por el tratamiento del tipo de señal.
Han et al. (2023)	Detecta, explica y adapta el <i>normality shift</i> .	Se diferencia por la aplicación a las series OT del proceso de agua , frente a la evidencia de origen NIDS/registros sobre la que se formula.
Umer et al. (2020); Raman & Mathur (2022a)	Integran enfoques basados en diseño y en datos para generar invariantes.	La novedad no está en la fusión, sino en la condicionalidad al régimen y en el protocolo de transferencia entre plantas.
Koutroulis et al. (2023)	Detección causal-estructural en SWaT (F1≈0,941, cero falsas alarmas, cuatro ataques no detectados).	Lo causal se posiciona como extensión o exploración , no como primicia; la atribución se trata como descripción de qué asociación se rompe, no como afirmación de causa.

La tesis se sitúa, por tanto, en la integración de tres elementos que la literatura aborda por separado: (i) la detección por ruptura de asociaciones condicionada al régimen, (ii) un protocolo de transferencia entre plantas y (iii) una evaluación realista de despliegue,

aplicados específicamente a las series OT del proceso de agua. El contexto operativo explícito (el modelo de información y el papel de la ontología) es el hilo que conecta la detección con la transferencia, y es precisamente donde el estado del arte está más vacío para el dominio hídrico: un hueco real, de respaldo todavía débil, que el trabajo aborda con prudencia como aportación del hilo teórico.

Sobre este mapa, los huecos que el trabajo puede llenar son cuatro: la ausencia de un protocolo canónico de transferencia entre plantas con métricas realistas de despliegue reportadas conjuntamente; la descomposición experimental de cuánto del rendimiento publicado se debe a artefactos de evaluación frente a la capacidad real bajo régimen cambiante; una arquitectura régimen-condicionada evaluada en series OT de proceso de agua; y la distinción operativa entre *proxy* y causa, validando la atribución a nivel de ventana de ataque sobre datos de agua, en la línea abierta por Fung et al. (2024).

6. Interés científico y aplicabilidad

El interés científico de la propuesta está en desplazar el foco de la detección de anomalías en infraestructuras hídricas desde el rendimiento en banco de pruebas hacia los factores que condicionan su utilidad operativa, y en estimar el efecto observado de cada uno. El valor esperado no es un detector, sino un método y unos principios.

En primer lugar, una caracterización controlada de la brecha: estimar, dentro del diseño experimental considerado y de forma condicional al pipeline, qué parte del rendimiento publicado se debe a artefactos de evaluación (la selección de umbral con oráculo y el ajuste por puntos) y qué parte a la naturaleza no estacionaria y dependiente del régimen del sistema. Identificar qué factor presenta mayor efecto observado sobre el rendimiento ofrece una orientación (no una receta operativa) sobre dónde concentrar el esfuerzo de ingeniería; su transferibilidad más allá del dominio hídrico se plantea como hipótesis a explorar, no como propiedad establecida. Esta caracterización responde a una necesidad que la literatura sugiere: estudios controlados que separen el efecto de los artefactos de evaluación del efecto de la deriva y del régimen.

En segundo lugar, un conjunto de principios de diseño que el programa busca validar empíricamente: la separación sistemática de lo que la literatura suele colapsar (el modelo frente al criterio de decisión, las variables discretas frente a las continuas, la rareza estadística frente a la consecuencia operativa). El interés metodológico de esta formulación no depende de qué fracción resulte atribuida a cada factor; ahora bien, si la ventaja del mecanismo propuesto sobre los baselines triviales no se sostiene tras un cambio de régimen o de banco de pruebas, el programa se reorienta hacia la robustez y la transferibilidad, según el criterio de corte declarado en la sección 2.2. La detección fiable, la robustez frente a la deriva, la explicabilidad y la estructuración del contexto se mantienen como dimensiones del estudio, subordinadas a la pregunta y no planteadas como frentes paralelos.

En cuanto a la aplicabilidad, los beneficiarios directos son los operadores hídricos (que obtendrían criterios para evaluar y desplegar detectores sin las ilusiones de rendimiento que introduce la selección de umbral con oráculo) y los reguladores y organismos de supervisión, para quienes la detección fiable y a la cadencia real de la planta es la condición que vuelve verificable la obligación de notificación de la NIS2. El encaje con la Estrategia Española de Ciencia, Tecnología e Innovación, con la transición digital del ciclo del agua y con la protección de infraestructuras críticas es directo, y se conserva como motivación y como ciclo de relevancia del marco DSR, no como promesa de despliegue: la validación naturalista, con datos de planta real y operador en el lazo, se declara trabajo futuro condicionado a acuerdos con operadores del sector. El enfoque encaja, por su orientación a métodos robustos, fiables e interpretables para sistemas ciberfísicos industriales, con líneas temáticas activas en revistas del área. La plataforma resultante, reproducible y empaquetada en contenedores, podría servir de base para la continuidad de la línea iniciada con el proyecto TrueData; la dependencia mundial de la desalación y la escalada de ciberataques contra infraestructuras hídricas dan a la detección fiable, robusta y explicable una pertinencia que trasciende el contexto español y europeo.

7. Bibliografía

- Adepu, S., & Mathur, A. (2021). Distributed attack detection in a water treatment plant: Method and case study. *IEEE Transactions on Dependable and Secure Computing*, 18(1), 86-99. <https://doi.org/10.1109/TDSC.2018.2875008>
- Alnegheimish, S., He, Z., Reimherr, M., Chandrayan, A., Pradhan, A., & D'Angelo, L. (2025). M2AD: Multi-sensor multi-system anomaly detection through global scoring and calibrated thresholding. *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics (AISTATS)*, PMLR 258, 4384-4392.
- Alves, B. C. F., Pinho, A. J., & Gouveia, S. (2026). Unified taxonomy for multivariate time series anomaly detection using deep learning. *arXiv preprint arXiv:2603.18941*.
- Anadolu Agency. (2025). Middle East confronts intensifying water crisis as desalination becomes lifeline for region.
- Audibert, J., Michiardi, P., Guyard, F., Marti, S., & Zuluaga, M. A. (2020). USAD: UnSupervised anomaly detection on multivariate time series. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '20)*, 3395-3404. <https://doi.org/10.1145/3394486.3403392>
- Barakat, G., Gupta, H., D'Agati, L., Tricomi, G., Longo, F., Merlino, G., & Puliafito, A. (2025). State-based modeling and anomaly detection in industrial systems using DEVS. *2025 IEEE International Conference on Smart Computing (SMARTCOMP)*, 474-479. <https://doi.org/10.1109/SMARTCOMP65954.2025.00108>
- Bayram, F., Ahmed, B. S., & Kassler, A. (2022). From concept drift to model degradation: An overview on performance-aware drift detectors. *Knowledge-Based Systems*, 245, 108632. <https://doi.org/10.1016/j.knosys.2022.108632>
- Billings, S. A. (2013). *Nonlinear system identification: NARMAX methods in the time, frequency, and spatio-temporal domains*. John Wiley & Sons.
- Cai, J., Wei, Z., & Luo, J. (2024). ICS anomaly detection based on sensor patterns and actuator rules in spatiotemporal dependency. *IEEE Transactions on Industrial Informatics*, 20(8), 10647-10656.

<https://doi.org/10.1109/TII.2024.3393528>

- Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys*, 41(3), 1-58. <https://doi.org/10.1145/1541880.1541882>
- Chen, Z., Chen, D., Zhang, X., Yuan, Z., & Cheng, X. (2021). Learning graph structures with transformer for multivariate time-series anomaly detection in IoT. *IEEE Internet of Things Journal*, 9(12), 9179-9189.
- CISA. (2023). IRGC-affiliated cyber actors exploit PLCs in multiple sectors, including U.S. water and wastewater systems facilities. *Cybersecurity Advisory AA23-335A*.
- Claroty Team82. (2024). IOCONTROL: A custom-built IoT/OT malware deployed by Iran-affiliated CyberAv3ngers. Claroty Research Report.
- Consejo de Ministros. (2025). Anteproyecto de Ley de Coordinación y Gobernanza de la Ciberseguridad, por el que se transpone la Directiva (UE) 2022/2555 (NIS2) al ordenamiento jurídico español (en tramitación). Referencia del Consejo de Ministros de 14 de enero de 2025.
- De Maesschalck, R., Jouan-Rimbaud, D., & Massart, D. L. (2000). The Mahalanobis distance. *Chemometrics and Intelligent Laboratory Systems*, 50(1), 1-18.
- Deng, A., & Hooi, B. (2021). Graph neural network-based anomaly detection in multivariate time series. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(5), 4027-4035.
- Directiva (UE) 2022/2555 del Parlamento Europeo y del Consejo, de 14 de diciembre de 2022, relativa a medidas destinadas a garantizar un elevado nivel común de ciberseguridad en toda la Unión (NIS2). *Diario Oficial de la Unión Europea*, L 333, 80-152.
- Dong, Y., Chen, K., & Ma, Z. (2023). Comparative study on semi-supervised learning applied for anomaly detection in hydraulic condition monitoring system. *2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, 1702-1708. <https://doi.org/10.1109/SMC53992.2023.10394193>
- Erba, A., Taormina, R., Galelli, S., Pogliani, M., Carminati, M., Zanero, S., & Tippenhauer, N. O. (2020). Constrained concealment attacks against reconstruction-based anomaly detectors in industrial control systems. *Proceedings of the 36th Annual Computer Security Applications Conference (ACSAC '20)*, 480-495. <https://doi.org/10.1145/3427228.3427660>
- Feng, C., Palleti, V. R., Mathur, A., & Chana, D. (2019). A systematic framework to generate invariants for anomaly detection in industrial control systems. *Proceedings of the Network and Distributed System Security Symposium (NDSS 2019)*.
- Franco de la Peña, M., Perales Gómez, Á. L., & Fernández Maimó, L. (2025). ShaTS: A Shapley-based explainability method for time series artificial intelligence models applied to anomaly detection in Industrial Internet of Things. *arXiv preprint arXiv:2506.01450*.
- Fung, C., Srinarasi, S., Lucas, K., Phee, H. B., & Bauer, L. (2022). Perspectives from a comprehensive evaluation of reconstruction-based anomaly detection in industrial control systems. *En Computer Security – ESORICS 2022 (LNCS 13556, pp. 493-513)*. Springer. https://doi.org/10.1007/978-3-031-17143-7_24
- Fung, C., Zeng, E., & Bauer, L. (2024). Attributions for ML-based ICS anomaly detection: From theory to practice. *Proceedings of the 2024 Network and Distributed System Security Symposium (NDSS)*. <https://doi.org/10.14722/ndss.2024.23216>
- Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), 1-37. <https://doi.org/10.1145/2523813>
- Gao, Z., Cecati, C., & Ding, S. X. (2015). A survey of fault diagnosis and fault-tolerant techniques, Part I: Fault diagnosis with model-based and signal-based approaches. *IEEE Transactions on Industrial Electronics*, 62(6), 3757-3767. <https://doi.org/10.1109/TIE.2015.2417501>
- Garg, A., Zhang, W., Samaran, J., Savitha, R., & Foo, C.-S. (2021). An evaluation of anomaly detection and diagnosis in multivariate time series. *IEEE Transactions on Neural Networks and Learning Systems*,

33(6), 2508-2517. <https://doi.org/10.1109/TNNLS.2021.3105827>

- Ghaeini, H. R., Antonioli, D., Brasser, F., Sadeghi, A.-R., & Tippenhauer, N. O. (2018). State-aware anomaly detection for industrial control systems. *Proceedings of the 33rd Annual ACM Symposium on Applied Computing (SAC)*, 1620-1628. <https://doi.org/10.1145/3167132.3167305>
- Giraldo, J., Urbina, D., Cardenas, A., Valente, J., Faisal, M., Ruths, J., Tippenhauer, N. O., Sandberg, H., & Candell, R. (2018). A survey of physics-based attack detection in cyber-physical systems. *ACM Computing Surveys*, 51(4), 1-36.
- Givehchi, O., Landsdorf, K., Simoens, P., & Jasperneite, J. (2017). Interoperability for industrial cyber-physical systems: An approach for legacy systems. *IEEE Transactions on Industrial Informatics*, 13(6), 3370-3378.
- Goh, J., Adepu, S., Junejo, K. N., & Mathur, A. (2017). A dataset to support research in the design of secure water treatment systems. In G. Havarneanu, R. Setola, H. Nassopoulos, & S. Wolthusen (Eds.), *Critical Information Infrastructures Security (CRITIS 2016)*, LNCS 10242 (pp. 88-99). Springer.
- Gregor, S., & Hevner, A. R. (2013). Positioning and presenting design science research for maximum impact. *MIS Quarterly*, 37(2), 337-355. <https://doi.org/10.25300/MISQ/2013/37.2.01>
- Haller, A., Janowicz, K., Cox, S., Le Phuoc, D., Taylor, K., et al. (2019). The modular SSN ontology: A joint W3C and OGC standard specifying the semantics of sensors, observations, sampling, and actuation. *Semantic Web*, 10(1), 9-32.
- Han, D., et al. (2023). Anomaly detection in the open world: Normality shift detection, explanation, and adaptation. *Proceedings of the 2023 Network and Distributed System Security Symposium (NDSS)*.
- Hevner, A. R. (2007). A three cycle view of design science research. *Scandinavian Journal of Information Systems*, 19(2), 87-92.
- Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75-105.
- Heydari, V., & Nyarko, K. (2026). Alarm-budgeted event-level evaluation of ICS anomaly detection: Lessons from SWaT and WADI. *IEEE Access*, 14, 17585-17609. <https://doi.org/10.1109/ACCESS.2026.3659034>
- Huet, A., Navarro, J. M., & Rossi, D. (2022). Local evaluation of time series anomaly detection algorithms. *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '22)*, 635-645. <https://doi.org/10.1145/3534678.3539339>
- ISA-95/IEC 62264. (s.f.). Enterprise-control system integration. International Society of Automation.
- Jarwar, M. A., Watson, J., & Ali, S. (2025). Modeling industrial IoT security using ontologies: A systematic review. *IEEE Open Journal of the Communications Society*, 6, 2792-2821. <https://doi.org/10.1109/OJCOMS.2025.3532224>
- Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Transactions of the ASME, Journal of Basic Engineering*, 82(1), 35-45. <https://doi.org/10.1115/1.3662552>
- Karabulut, E., Pileggi, S. F., Groth, P., & Degeler, V. (2023). Ontologies in digital twins: A systematic literature review. *Future Generation Computer Systems*, 153, 442-456. <https://doi.org/10.1016/j.future.2023.12.013>
- Kim, S., Choi, K., Choi, H.-S., Lee, B., & Yoon, S. (2022). Towards a rigorous evaluation of time-series anomaly detection. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36(7), 7194-7201.
- Koutroulis, G., Mutlu, B., & Kern, R. (2023). A causality-inspired approach for anomaly detection in a water treatment testbed. *Sensors*, 23(1), 257. <https://doi.org/10.3390/s23010257>
- Lamberts, O., Wolsing, K., Wagner, E., Pennekamp, J., Bauer, J., Wehrle, K., & Henze, M. (2023). SoK: Evaluations in industrial intrusion detection research. *Journal of Systems Research*, 3(1). <https://doi.org/10.5070/SR33162445>

- Lemos, R. (2021). Hacker tried to poison Florida city's water supply. Dark Reading.
- Li, K., Tang, Z., Liang, S., Li, Z., & Liang, B. (2025). MLAD: A multi-task learning framework for anomaly detection. *Sensors*, 25(13), 4115. <https://doi.org/10.3390/s25134115>
- Li, L., Yan, J., Wen, Q., Jin, Y., & Yang, X. (2023). Learning robust deep state space for unsupervised anomaly detection in contaminated time-series. *IEEE Transactions on Knowledge and Data Engineering*, 35(6), 6058-6072. <https://doi.org/10.1109/TKDE.2022.3171562>
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. 2008 IEEE International Conference on Data Mining (ICDM), 413-422.
- Lu, J., Liu, A., Dong, F., Gu, F., Gama, J., & Zhang, G. (2019). Learning under concept drift: A review. *IEEE Transactions on Knowledge and Data Engineering*, 31(12), 2346-2363. <https://doi.org/10.1109/TKDE.2018.2876857>
- Lubba, C. H., Sethi, S. S., Knaute, P., Schultz, S. R., Fulcher, B. D., & Jones, N. S. (2019). catch22: CAnonical time-series CHaracteristics. *Data Mining and Knowledge Discovery*, 33(6), 1821-1852.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Lv, J., Wang, Y., & Chen, H. (2023). Adaptive multivariate time-series anomaly detection. *Information Processing & Management*, 60(4), 103383.
- Malarkkan, A. V., Bai, H., Wang, X., Kaushik, A., Wang, D., & Fu, Y. (2025). Rethinking spatio-temporal anomaly detection: A vision for causality-driven cybersecurity. *arXiv preprint arXiv:2507.08177*.
- March, S. T., & Smith, G. F. (1995). Design and natural science research on information technology. *Decision Support Systems*, 15(4), 251-266. [https://doi.org/10.1016/0167-9236\(94\)00041-2](https://doi.org/10.1016/0167-9236(94)00041-2)
- Mathur, A. P., & Tippenhauer, N. O. (2016). SWaT: A water treatment testbed for research and training on ICS security. 2016 International Workshop on Cyber-Physical Systems for Smart Water Networks (CySWater), 31-36.
- Mathuros, K., Venugopalan, S., & Adepur, S. (2024). WaXAI: Explainable anomaly detection in industrial control systems and water systems. *Proceedings of the 10th ACM Cyber-Physical System Security Workshop (CPSS '24)*. <https://doi.org/10.1145/3626205.3659147>
- Meli, D. (2024). Explainable online unsupervised anomaly detection for cyber-physical systems via causal discovery from time series. 2024 IEEE 20th International Conference on Automation Science and Engineering (CASE), 4120-4125. <https://doi.org/10.1109/CASE59546.2024.10711445>
- Pal, K., Adepur, S., & Goh, J. (2017). Effectiveness of association rules mining for invariants generation in cyber-physical systems. 2017 IEEE 18th International Symposium on High Assurance Systems Engineering (HASE), 124-127. <https://doi.org/10.1109/HASE.2017.21>
- Paparrizos, J., Boniol, P., Palpanas, T., Tsay, R. S., Elmore, A. J., & Franklin, M. (2022). Volume under the surface: A new accuracy evaluation measure for time-series anomaly detection. *Proceedings of the VLDB Endowment*, 15(11), 2774-2787. <https://doi.org/10.14778/3551793.3551830>
- Peffer, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45-77.
- Qiu, X., et al. (2025). TAB: Unified benchmarking of time series anomaly detection methods. *Proceedings of the VLDB Endowment*, 18(8), 2775-2789. <https://doi.org/10.14778/3746405.3746407>
- Raman, M. R. G., & Mathur, A. P. (2022a). A hybrid physics-based data-driven framework for anomaly detection in industrial control systems. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 52(9), 6003-6014. <https://doi.org/10.1109/TSMC.2021.3131662>
- Raman, M. R. G., & Mathur, A. P. (2022b). AICrit: A unified framework for real-time anomaly detection in water treatment plants. *Journal of Information Security and Applications*, 64, 103046.

<https://doi.org/10.1016/j.jisa.2021.103046>

- Real Decreto-ley 12/2018, de 7 de septiembre, de seguridad de las redes y sistemas de información. Boletín Oficial del Estado, núm. 218, de 8 de septiembre de 2018.
- Rezende, D. J., & Mohamed, S. (2015). Variational inference with normalizing flows. *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 1530-1538.
- Runge, J., Nowack, P., Kretschmer, M., Flaxman, S., & Sejdinovic, D. (2019). Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*, 5(11), eaau4996.
- Stouffer, K., Pease, M., Tang, C., Zimmerman, T., Pillitteri, V., & Lightman, S. (2023). Guide to Operational Technology (OT) Security. NIST Special Publication 800-82 Rev. 3. <https://doi.org/10.6028/NIST.SP.800-82r3>
- Su, Y., Zhao, Y., Niu, C., Liu, R., Sun, W., & Pei, D. (2019). Robust anomaly detection for multivariate time series through stochastic recurrent neural network. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2828-2837. <https://doi.org/10.1145/3292500.3330672>
- Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 27.
- The National. (2026). Kuwaiti power and desalination plant hit in Iranian strike as ministry reassures on operations.
- ThingsBoard Community Edition. (s.f.). IoT platform documentation. <https://thingsboard.io/docs/>
- Tuli, S., Casale, G., & Jennings, N. R. (2022). TranAD: Deep transformer networks for anomaly detection in multivariate time series data. *Proceedings of the VLDB Endowment*, 15(6), 1201-1214. <https://doi.org/10.14778/3514061.3514067>
- U.S. Government Accountability Office. (2024). Critical infrastructure protection: EPA urgently needs a strategy to address cybersecurity risks to water systems (Report GAO-24-106744).
- Umer, M. A., Mathur, A., Junejo, K. N., & Adepu, S. (2020). Generating invariants using design and data-centric approaches for distributed attack detection. *International Journal of Critical Infrastructure Protection*, 28, 100356. <https://doi.org/10.1016/j.ijcip.2020.100356>
- Unna, Y. (2020). Citado en: Heller, A. Israeli cyber chief: Major attack on water systems thwarted. Associated Press / The Times of Israel.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Venable, J., Pries-Heje, J., & Baskerville, R. (2016). FEDS: A framework for evaluation in design science research. *European Journal of Information Systems*, 25(1), 77-89. <https://doi.org/10.1057/ejis.2014.36>
- Wei, Z., Lv, F., Lu, X., Chen, X., Lv, S., & Sun, L. (2024). SSAD: State space-based anomaly detection in industrial control systems. *2024 20th International Conference on Mobility, Sensing and Networking (MSN)*, 479-486. <https://doi.org/10.1109/MSN63567.2024.00072>
- Wu, R., & Keogh, E. J. (2023). Current time series anomaly detection benchmarks are flawed and are creating the illusion of progress. *IEEE Transactions on Knowledge and Data Engineering*, 35(3), 2421-2429. <https://doi.org/10.1109/TKDE.2021.3112126>
- Wu, Z., Pan, S., Long, G., Jiang, J., Chang, X., & Zhang, C. (2020). Connecting the dots: Multivariate time series forecasting with graph neural networks. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '20)*, 753-763.
- Zamanzadeh Darban, Z., Webb, G. I., Pan, S., Aggarwal, C., & Salehi, M. (2024). Deep learning for time series anomaly detection: A survey. *ACM Computing Surveys*, 57(1), art. 15. <https://doi.org/10.1145/3691338>

- Zhan, J., Wu, C., Yang, C., Miao, Q., & Ma, X. (2024). HFN: Heterogeneous feature network for multivariate time series anomaly detection. *Information Sciences*, 670, 120626.
- Zhao, H., Wang, Y., Duan, J., Huang, C., Cao, D., Tong, Y., Xu, B., Bai, J., Tong, J., & Zhang, Q. (2020). Multivariate time-series anomaly detection via graph attention network. 2020 IEEE International Conference on Data Mining (ICDM), 841-850. <https://doi.org/10.1109/ICDM50108.2020.00093>
- Zhou, A., Yang, R., Yan, K., et al. (2024). HGNAS: Hardware-aware graph neural architecture search for edge devices. *IEEE Transactions on Computers*.